

TALLER B5-T1 · MIAx

Generación de datos financieros sintéticos

¿Puede la generación sintética compensar la escasez de episodios de caída severa en el mercado?

Raúl · Pietro · Alonso



EL PROBLEMA

Anticipar una caída severa del S&P 500

A partir de la ventana de rentabilidades de los últimos 60 días, predecir si la cartera sufrirá un retroceso pronunciado durante los 30 días siguientes.

Universo

23 valores del S&P 500 con historia completa desde 1962

Entrada X

ventana de 60 sesiones × 23 activos de rentabilidades logarítmicas

Etiqueta y

1 si el drawdown a 30 días supera el $-7,91\%$ · umbral calibrado solo con train

Clasificador

CNN 1D — idéntica arquitectura en las 4 configuraciones comparadas

Métrica

PR-AUC sobre la clase positiva (no accuracy: clase minoritaria)

16.180


ventanas · 10 % positivas

¿Por qué $-7,91\%$?

EN ESTE TRABAJO

11.326 ventanas de entrenamiento

- 1 Se decide marcar como estrés el 10 % peor
- 2 Se ordenan los drawdowns de peor a mejor
- 3 La ventana nº1.133 desde abajo cae $-7,91\%$
- 4 El corte de estrés queda en $-7,91\%$



Detectar un evento raro, no predecir un promedio

El problema de este trabajo: **anticipar si la cartera va a sufrir una caída severa en los 30 días siguientes.**

Se parte del ejercicio de la sesión 1 (mismo S&P 500, misma ventana de 60 días, misma red convolucional). Cambia lo que se predice:

	Sesión 1 (ejercicio guiado)	Este trabajo
Qué predice	rentabilidad media a 30 días	caída severa a 30 días
Tipo de problema	regresión	clasificación de un evento raro
Partición	aleatoria (train_test_split)	cronológica, con embargo
Escasez de datos	ninguna: etiqueta continua siempre válida	real: 51 episodios en 45 años

La rentabilidad media no escasea nunca. Reformular el problema como detección de un evento raro es lo que crea la escasez de datos

1.137 ventanas positivas son, en realidad, 51 episodios

Dos ventanas separadas por un día comparten 59 de sus 60 sesiones. El recuento que importa no es el de ventanas, sino el de episodios independientes.

1.137

**ventanas positivas en
el conjunto de entrenamiento**

*cifra que en apariencia
no indica escasez*

51

**episodios de crisis
independientes en 45 años**

*en test: 243 ventanas son
solo 8 episodios*

Y los tramos recientes del entrenamiento no contienen ningún episodio:

últimas 500 ventanas

0 positivas (0,0 %)

últimas 1.000 ventanas

0 positivas (0,0 %)

últimas 2.000 ventanas

257 positivas (12,8 %)

Tres decisiones que sostienen la comparación

1

Partición cronológica con embargo

train 1962–2007 · validación 2007–2016 · test 2017–2026, separados por un hueco de 90 sesiones. Un reparto aleatorio de ventanas solapadas infla las métricas.

2

Los generadores solo ven el presupuesto real

las mismas 3.000 ventanas de entrenamiento que el clasificador, nunca el histórico completo, nunca validación o test.

3

Arquitectura y protocolo únicos

misma CNN clasificadora para las 4 configuraciones; búsqueda de arquitectura sobre datos reales

Determinismo, con un matiz honesto

El mismo código, semillas y dataset.npz dieron referencias distintas en tres máquinas del grupo (0,225 / 0,241 / 0,244) por orden de las operaciones en punto flotante. Por eso la comparación se apoya en la dispersión entre semillas y no en el valor puntual.

Tres paradigmas distintos, más una referencia mínima

Ruido gaussiano

perturbación de datos reales

notebook 03

segundos

cGAN

adversaria condicional

notebook 04

8 min

CVAE

variable latente condicional

notebook 05

4 min

Difusión

difusión condicional

notebook 06




20 min

No son tres variantes de la misma idea: cubren las tres formas de estimar la distribución. Densidad implícita en el cGAN, que nunca la escribe y aprende del gradiente del discriminador; densidad explícita aproximada en el CVAE, que la modela con una variable latente; y basado en score en la difusión, que aprende a deshacer una degradación conocida. Los tres son condicionales por clase, porque lo que escasea no son observaciones sino episodios de estrés, y hay que poder pedirlos. El ruido gaussiano no compite con ellos: fija el mínimo exigible.

Cada uno genera 12.000 muestras y se evalúa con el mismo barrido de proporciones {0, 0,25, 0,5, 1, 2, 4} sobre el presupuesto real, con 5 semillas por configuración.

EL ENTRENAMIENTO

Los tres generadores convergen, y uno obligó a cambiar la formulación



El criterio no es el mismo para los tres

En el cGAN la pérdida no baja: converge cuando el discriminador acierta 0,447, junto al 0,50 que significa que ya no distingue. En el CVAE y la difusión sí baja, y basta con que se aplane.

La formulación clásica no converge

Estimando el ruido añadido, el error se estancaba en 0,80 sobre un máximo de 1,00 y el muestreo divergía. Estimando la ventana limpia baja a 0,338.

La red extrae señal , pero no supera a un modelo lineal

0,225

PR-AUC test
(CNN, sin sintéticos)

0,104

clasificador
sin información


0,350

regresión logística
sobre 6 descriptores

La regresión logística usa seis descriptores agregados de la ventana: volatilidad, retorno acumulado, drawdown corriente, mínimo diario, dispersión entre activos, rentabilidad absoluta media. Entrenada sobre el histórico completo. La comparación no es simétrica, pero acota lo que se está midiendo: la convolución no aporta nada sobre un resumen estadístico sencillo.

El coeficiente de variación del PR-AUC entre semillas es 0,40 en test frente a 0,06 en validación: el test cubre un único régimen con solo 8 episodios de estrés.

PR-AUC en test según la proporción de sintéticos



Lectura

Ninguna curva se mantiene por encima de la referencia de forma sostenida.

El **cGAN** es el único cuya mejor variación es exactamente cero.

Ruido, CVAE y difusión mejoran algo a proporción 0,25 y degradan a partir de 0,5–1.

¿Alguna de esas subidas resiste el contraste?

20

configuraciones
contrastadas


0

mejoras
significativas

6

degradaciones
significativas ($p < 0,05$)

Cuando la barra de dispersión cruza el cero, la subida no se distingue del ruido de la propia inicialización. Las cuatro la cruzan.



POR QUÉ NO


Los tres generadores neuronales fallan en lo que importa

El drawdown se mide sobre la cartera equiponderada: es la sincronía entre activos (la correlación) la que decide su magnitud.

	Desviación	Curtosis	Correlación	Novedad
Reales	0,241	2,20	0,266	1,00
Ruido gaussiano	0,248	1,83	0,249	0,22
cGAN	0,281	2,88	0,156 ↓	1,04
CVAE	0,047 ↓↓	1,28	0,768 ↑↑	0,56
Difusión	0,392 ↑	0,03 ↓↓	0,435 ↑	1,45

El CVAE genera ventanas casi planas (desviación cinco veces menor, correlación casi triple): los 23 activos se mueven al unísono. Es el suavizado característico de un autocodificador variacional llevado al extremo, y el generador que más daño hace al clasificador.

Realismo y utilidad no van de la mano



COSTE →

● **Ruido** segundos

● **CVAE** 4 min

● **cGAN** 8 min

● **Difusión** 20 min

→ *el inverso de la utilidad*

CONCLUSIÓN

Ningún generador justifica su coste frente a añadir ruido gaussiano

El problema no está limitado por el volumen de datos. La curva de aprendizaje del clasificador es plana en validación y descendente en test. Multiplicar por veinte las ventanas reales no mejora el resultado.

Los cuatro generadores se entrenan sobre los mismos 51 episodios escasos: ninguno puede fabricar crisis genuinamente nuevas. O copian el dato real (ruido), o producen novedad que no es estrés realista (cGAN, difusión), o suavizan en exceso (CVAE). Un generador solo ayudaría si aportara variedad que no está en los datos — y eso es justo lo que no puede inventar.

REPOSITORIO

**8 notebooks
reproducibles
de principio a fin**

Gracias — preguntas