

TALLER: B5-T1

Generación de Datos Financieros sintéticos

Datos básicos:

- Grupos de 3 estudiantes definidos por el profesor.
- Entrega el día 3 septiembre a través del aula virtual a las 18:00.
- El entregable es un repositorio de GitHub y un documento en formato PDF con la presentación.
- El día 3 de septiembre hará una presentación cada grupo de 5 minutos.

1. Objetivo de la práctica

Por un lado el objetivo principal es probar diferentes métodos de generación de datos sintéticos basados en redes neuronales. Además vamos a analizar el efecto de uso de datos sintéticos en el entrenamiento de modelos.

2. Contexto del problema

La práctica se desarrolla en forma de taller semi-guiado, estructurado en dos sesiones prácticas de 2,5 horas cada una:

Diseño de un ejemplo (Sesión 1): Se desarrollará un ejemplo de principio a fin donde se entrene uno o varios modelos generativos usando datos financieros. Una vez entrenados, se generarán datos sintéticos y se entrenará un segundo modelo para resolver el problema financiero. De este modelo se entrenarán distintas versiones, cada una utilizando una cantidad distinta de datos reales y sintéticos. Se compararán los resultados para cada versión del modelo.

Exposición de las soluciones (Sesión 2): Presentación y defensa técnica de los resultados, 5 minutos mas preguntas.

La tarea se entregará justo antes de la sesión 2.

3. Datos disponibles

En este taller los datos son a elección de los estudiantes. El grupo debe plantear un problema financiero que pudiera beneficiarse de tener datos sintéticos.

4. Tarea del estudiante

Los estudiantes tienen las siguientes tareas:

1. **Definición de un problema financiero.** Los estudiantes deben buscar un problema financiero interesante que pudiera beneficiarse de tener datos sintéticos.
2. **Diseño y entrenamiento de 3 tipos distintos de modelo generativo:** Se deben elegir 3 tipos distintos de modelo generativo de los vistos en clase y entrenarlos con los datos elegidos. Además se debe incluir un cuarto modelo simple, por ejemplo que coja datos originales y les añada ruido.
3. **Generación de datasets sintéticos:** Una vez entrenados los modelos generativos se deben generar datos sintéticos con cada modelo. Con estos datos generaremos datasets que tengan distinto porcentaje de datos sintéticos y reales.
4. **Entrenamiento:** Usando los datos reales se buscará una arquitectura valida para resolver el problema. Usando la misma arquitectura se entrenaran distintas versiones del modelo, una versión por cada dataset generado en el punto anterior.
5. **Análisis de resultados:** Se analizarán los resultados obtenidos, se verá como meter mas o menos datos sintéticos modifica el comportamiento del modelo, y se comparará entre los distintos tipos de modelos generativos usados (incluyendo el modelo simple).

5. Entregables

Se deberá entregar un github con los modelos y los resultados, y una presentación (report en pdf) a través del aula virtual.

Contenido obligatorio del GitHub:

- El código de entrenamiento, optimización y evaluación de cada modelo. El código debe generar todas las gráficas y tablas reportadas.
- Para cada entrenamiento, incluir las curvas de loss donde se vea que el modelo ha convergido.
- Gráficos de análisis de los resultados.
- El readme debe contener la suficiente información para entender todo el proyecto y los resultados.

Contenido de la presentación:

- Explicación y justificación del problema seleccionado.
- Explicación y justificación de los modelos generativos seleccionados.
- Entrenamiento de los modelos.
- Resultados obtenidos.

6. Criterios de evaluación

- (20 %) Github
- (80 %) Presentación. Se presentará el pdf entregado en el aula virtual. Cada grupo hará una presentación corta (5 minutos) explicando sus resultados.